Universidad Nacional Autónoma de México

Facultad de Ciencias

Curso de Almacenes y Minería de Datos

Práctica 5: Normalización de Datos Numéricos, Reducción de Dimensionalidad (Coeficiente de Correlación y PCA) y Dashboard sobre Consumo Eléctrico Doméstico

Impartido por:
Jessica Santizo Galicia

Ayudante:
Diego Antonio Villalba González

Ayud. Lab.:
Emma Alicia Jiménez Sánchez

Fecha de entrega: Por definir

Práctica: Preparación de Datos — Normalización Numérica, Reducción de Dimensionalidad y Dashboard

1. Objetivo

El objetivo de esta práctica es que el alumno prepare un conjunto de datos de series de tiempo para el entrenamiento posterior de modelos de aprendizaje automático. Para ello deberá: (1) aplicar el **preprocesamiento de datos** visto en prácticas anteriores (normalización de variables cualitativas, deduplicación y casteo de tipos de datos); (2) aplicar **normalización de variables numéricas**; (3) realizar **reducción de dimensionalidad** mediante el **coeficiente de correlación de Pearson** y el **Análisis de Componentes Principales (PCA)**; y (4) desarrollar un **dashboard interactivo** con métricas, KPIs, gráficas y tablas detalladas que permita explorar los datos y comunicar hallazgos. La **reducción de numerosidad por muestreo** se incluye como un ejercicio **opcional**, no obligatorio para la entrega.

2. Introducción

2.1. El dataset de la práctica

A partir de esta práctica se trabaja con el dataset **Individual Household Electric Power Consumption**, publicado en el *UCI Machine Learning Repository*, disponible en https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption. Sus características generales, según el repositorio, son:

Característica	**Valor**
Tipo de dataset (*Dataset Characteristics*)	Multivariado, series de tiempo
Área temática (*Subject Area*)	Física y Química
Tareas asociadas (*Associated Tasks*)	Regresión, agrupamiento (*clustering*)

Se trata de mediciones de consumo eléctrico de un hogar registradas a lo largo del tiempo, con más de dos millones de registros. Este volumen, junto con su naturaleza multivariada y temporal, lo hace adecuado para esta práctica por tres razones:

- Al ser **multivariado**, las variables numéricas pueden estar en escalas distintas y presentar redundancia entre sí, lo que justifica la normalización y la reducción de dimensionalidad.
- Al ser de **series de tiempo**, el orden de los registros tiene significado, y esto debe tenerse presente al normalizar, al muestrear y al interpretar los resultados.

- Las tareas de **regresión** y **agrupamiento** que se plantean para el dataset dependen de que los datos estén correctamente escalados (en particular el agrupamiento, que se basa en distancias), por lo que esta práctica constituye la preparación de los datos para el entrenamiento de los modelos de las siguientes prácticas.

2.2. Conceptos de la práctica

- **Preprocesamiento de datos:**

  Conjunto de tareas de limpieza ya vistas en prácticas anteriores y que se vuelven a aplicar sobre este nuevo dataset: **normalización de variables cualitativas** (unificación de mayúsculas, espacios y acentos en campos de texto), **deduplicación** de registros y **casteo** de cada columna a su tipo de dato correcto, incluyendo los campos temporales. Asimismo, se atienden los valores faltantes que presente el dataset, tal como se hizo en prácticas anteriores.

- **Normalización de variables numéricas:** reescalamiento de las variables cuantitativas para que sean comparables entre sí y ninguna domine a las demás en las técnicas basadas en distancias o en varianza. Las dos técnicas principales son *min-max* y *z-score*; el alumno debe elegir una y justificar su decisión.

- **Reducción de dimensionalidad por selección de variables (coeficiente de correlación de Pearson):** se utiliza entre **variables cuantitativas** para detectar pares altamente correlacionados (redundantes), de modo que se pueda eliminar una de ellas sin perder información relevante. El coeficiente toma valores entre -1 y 1, y mide la intensidad de la relación lineal entre dos variables.

- **Reducción de dimensionalidad por extracción de características (PCA):** a diferencia del criterio anterior, que *selecciona* un subconjunto de las variables originales, el **Análisis de Componentes Principales** *construye* nuevas variables (componentes principales) como combinaciones lineales de las originales, ortogonales entre sí y ordenadas de mayor a menor varianza explicada. Matemáticamente, los componentes son los vectores propios de la matriz de covarianza de los datos estandarizados, y la varianza que explica cada uno es su valor propio λ_i:

$$\text{Varianza explicada del componente } i = \frac{\lambda_i}{\sum_{j=1}^{p} \lambda_j}$$

  Conservar los primeros $k < p$ componentes permite representar los datos en menos dimensiones perdiendo la menor cantidad posible de información.

- **Dashboard:** herramienta interactiva que resume el dataset mediante indicadores clave (KPIs), gráficas y tablas, y que permite al usuario filtrar y explorar la información para encontrar patrones y hallazgos.

- **Reducción de numerosidad por muestreo (opcional):** reduce el número de *filas* reemplazando el conjunto completo por una muestra representativa más pequeña. Se

pueden estudiar el muestreo aleatorio simple (con y sin reemplazo), el muestreo sistemático y el muestreo estratificado. En series de tiempo debe tenerse especial cuidado, pues un muestreo aleatorio puede alterar la estructura temporal de los datos.

3. Herramientas a Utilizar

- **polars** (o *pandas*), para la manipulación, limpieza y normalización de los datos.
- **NumPy**, para operaciones numéricas y cálculo de componentes.
- **SciPy**, para el cálculo del coeficiente de correlación y estadísticos de apoyo.
- **scikit-learn** (`MinMaxScaler`, `StandardScaler`, `PCA`), para la normalización numérica y el PCA.
- **Matplotlib / Seaborn**, para el mapa de calor de correlaciones, la gráfica de varianza explicada (*scree plot*) y la proyección de los componentes.
- **Streamlit**, para el desarrollo del dashboard. Es una **recomendación**. Mientras que se pueda ver y compartir el dashboard se puede hacer en cualquier herramienta.
- **Git y GitHub**, para el control de versiones y la entrega del repositorio.
- **Dataset Individual Household Electric Power Consumption (UCI).**
- **Colors:** Paleta de colores para el dashboard https://coolors.co/palettes/trending

4. Requisitos

- Haber descargado el dataset desde el *UCI Machine Learning Repository* y leído su descripción. https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption
- Conocimientos previos de tipos de datos (cualitativos/cuantitativos) y de las medidas de localización y variabilidad vistas en la Práctica 3.
- Conocimientos básicos de álgebra lineal (valores y vectores propios, matriz de covarianza).
- Cuenta de GitHub y entorno de Python configurado (`venv` y `requirements.txt`) con las bibliotecas necesarias, incluyendo `scipy`, `scikit-learn` y `streamlit`.

5. Desarrollo

En cada paso se indica **qué se debe hacer**. La elección de las variables con las que se trabaja, la implementación y las decisiones técnicas corresponden al alumno, quien deberá justificarlas. Esta práctica **no incluye cuestionario**: únicamente se solicita la justificación del proceso del proyecto, la cual se presenta en la presentación técnica y en el `README` del repositorio.

Paso 0: Creación del repositorio

Qué se debe hacer: Crear un **nuevo repositorio en GitHub**, independiente del de las prácticas anteriores, que conserve la **misma arquitectura** ya vista:

```
proyecto/
|-- data/
|   |-- data-raw/          # dato original, sin modificar
|   |-- data-processed/    # dato preparado
|-- src/
|   |-- cleaning/          # preprocesamiento y normalizacion
|   |-- ...                # modulos auxiliares del dashboard
|-- visualization/
|   |-- app.py             # codigo principal del dashboard
|-- README.md
|-- requirements.txt
```

El repositorio debe incluir:

- Un `README.md` que describa el proyecto, el dataset y su fuente, la estructura de carpetas, las instrucciones de instalación y ejecución del dashboard, y un resumen de las decisiones tomadas.
- Un `requirements.txt` con las dependencias necesarias para reproducir el proyecto.

Dado el tamaño del dataset, los datos originales no deben subirse al repositorio si superan los límites de GitHub; en ese caso, el `README` debe explicar cómo descargarlos y dónde colocarlos.

Paso 1: Carga e inspección inicial de los datos

Qué se debe hacer: Cargar el dataset original e inspeccionar su estado inicial: dimensiones, tipos de dato detectados, valores faltantes, rango temporal y estadísticos descriptivos básicos. Documentar los problemas de calidad encontrados.

Paso 2: Preprocesamiento de los datos

Qué se debe hacer: Implementar el preprocesamiento visto en prácticas anteriores:

- **Normalización de variables cualitativas:** unificar mayúsculas, espacios y acentos en los campos de texto o categóricos que existan.

- **Deduplicación:** identificar y eliminar registros duplicados, justificando el criterio utilizado.
- **Casteo de tipos de dato:** convertir cada columna a su tipo adecuado (numérico, temporal, categórico), cuidando el correcto manejo de los campos de fecha y hora.
- **Valores faltantes:** tratarlos con la estrategia que el alumno considere adecuada para una serie de tiempo, justificándola.

El resultado de este paso es un dataset limpio que se utiliza en todos los pasos siguientes.

Paso 3: Normalización de variables numéricas

Qué se debe hacer: Aplicar normalización numérica a las variables cuantitativas del dataset utilizando *min-max* o *z-score*. El alumno debe justificar por qué eligió la técnica, considerando, entre otros aspectos, la presencia de valores atípicos, las escalas de las variables y el uso posterior de los datos. Debe además tener en cuenta que, al tratarse de una serie de tiempo, los parámetros del escalamiento deben calcularse de forma que no se filtre información del futuro hacia el entrenamiento de los modelos, y explicar cómo lo consideró.

Paso 4: Reducción de dimensionalidad — Coeficiente de correlación de Pearson

Qué se debe hacer: Calcular la matriz de correlación de Pearson entre las variables cuantitativas del dataset y representarla mediante un mapa de calor. Identificar los pares de variables altamente correlacionadas (redundantes), definir y justificar un umbral de correlación, y decidir qué variables conservar y cuáles descartar, argumentando la decisión.

Paso 5: Reducción de dimensionalidad — Análisis de Componentes Principales (PCA)

Qué se debe hacer:

1. Verificar que las variables cuantitativas a utilizar estén estandarizadas.
2. Ajustar el PCA y obtener la varianza explicada por cada componente, así como la varianza explicada acumulada.
3. Generar la gráfica de varianza explicada (*scree plot*) y, con base en ella, **seleccionar el número de componentes** a conservar, justificando el criterio utilizado.
4. **Interpretar los *loadings***: explicar qué variables originales pesan más en cada componente retenido y qué representa cada componente.
5. Proyectar los datos en **dos dimensiones** y analizar qué patrones se observan.
6. Incorporar los componentes retenidos al dataset preparado.

Paso 6: Consolidación del dataset preparado

Qué se debe hacer: Guardar en `data/data-processed/` la versión final del dataset, ya limpio, con las variables numéricas normalizadas, con las variables redundantes descartadas según el Paso 4 y con los componentes principales incorporados. El archivo original en `data/data-raw/` no debe modificarse.

Paso 7: Desarrollo del dashboard

Qué se debe hacer: Desarrollar un dashboard interactivo, en Streamlit, que permita explorar el dataset, conforme a lo explicado en clase el 30 de septiembre y siguiendo esta organización del proyecto:

- **Carpeta `visualization/`:** debe contener únicamente el código principal que ejecuta y muestra el dashboard (por ejemplo, `app.py`).
- **Carpeta `src/`:** debe contener todo el código auxiliar que el dashboard utiliza, como la carga de datos, el cálculo de métricas y la creación de gráficos. El código principal importa estos módulos.

Datos de entrada: El dashboard debe leer el conjunto de datos procesado en los pasos anteriores, sin modificar el archivo original.

Contenido mínimo del dashboard:

- **Indicadores clave (KPIs) esenciales:** métricas resumen que permitan entender de un vistazo el comportamiento del dataset.
- **Gráficas:** visualizaciones que ayuden a comprender el comportamiento de los datos a lo largo del tiempo, sus distribuciones y las relaciones entre variables.
- **Tablas detalladas:** tablas que permitan consultar la información con mayor nivel de detalle.
- **Filtros interactivos:** controles que permitan segmentar la información (por ejemplo, por rango de fechas o por nivel de agregación temporal).

Se notificará con un día de anticipación a las personas seleccionadas para proyectar su trabajo y explicar, mediante *storytelling*, sus principales hallazgos e *insights*.

Para el desarrollo del dashboard se pueden apoyar de la inteligencia artificial para poder refinar la parte visual de su dashboard, más no se acepta que la inteligencia artificial el análisis de los datos para la creación del dashboard.

Paso 8 (opcional): Reducción de numerosidad por muestreo

Qué se debe hacer: Este paso **no es obligatorio para la entrega**. Quien decida realizarlo puede reducir el número de registros del dataset mediante una o más técnicas de muestreo (aleatorio simple con y sin reemplazo, sistemático o estratificado) y comparar qué tan representativa es cada muestra respecto al conjunto completo mediante estadísticos descriptivos. Debe considerar que, en una serie de tiempo, el muestreo puede alterar la estructura temporal, y justificar la técnica elegida en caso de utilizar la muestra en el dataset final.

6. Formato de Entrega

Se deben entregar los siguientes elementos:

1. **Dashboard** desarrollado en Streamlit, con las métricas, KPIs, gráficas y tablas detalladas, tal como se explicó el 30 de septiembre.

2. **Repositorio de GitHub** con la arquitectura ya vista, incluyendo el `README.md` y el `requirements.txt`.

3. **Presentación técnica de no más de 10 diapositivas**, con la siguiente estructura:

Sección	**Contenido**	**No.Diapositivas**
Contexto del dataset	Origen, características, tamaño, naturaleza temporal y tareas asociadas.	1
Preprocesamiento	Explicación del proceso de limpieza aplicado: normalización cualitativa, deduplicación, casteo de tipos y manejo de faltantes.	2
Hallazgos del dashboard	Hallazgos e *insights* observados a partir del dashboard.	3
Normalización numérica	Método utilizado y por qué se eligió.	1
Correlación de Pearson	Resultados, variables redundantes y decisiones tomadas.	1
PCA	Componentes retenidos, varianza explicada e interpretación.	1
Conclusiones	Conclusiones del proyecto.	1

La presentación debe contener la justificación del proceso del proyecto; no se entrega reporte ni cuestionario adicional.

7. Elementos a Calificar

La evaluación de la práctica se estructurará bajo los siguientes criterios de ponderación:

Criterio de Evaluación	Descripción Detallada	Ponderación
Repositorio y preprocesamiento	Arquitectura del repositorio, `README` y `requirements.txt`; correcta aplicación de normalización cualitativa, deduplicación y casteo de tipos.	15 %
Normalización numérica	Correcta normalización de las variables numéricas, con justificación técnica de la técnica elegida (*min-max* o *z-score*).	15 %
Correlación de Pearson	Correcta aplicación e interpretación del coeficiente, con una decisión justificada sobre qué variables conservar o eliminar.	15 %
PCA	Estandarización, selección justificada del número de componentes, interpretación de *loadings* y proyección en 2D.	20 %
Dashboard	Arquitectura del dashboard, métricas, KPIs, gráficas y tablas detalladas utilizadas para el entendimiento de los datos.	25 %
Presentación técnica	Claridad, cumplimiento de la estructura solicitada (máximo 10 diapositivas) y justificación del proceso.	10 %

El Paso 8 (muestreo) es opcional y no es requisito para la entrega.

8. Referencias

- Hebrail, G., & Berard, A. (2006). *Individual Household Electric Power Consumption* [Conjunto de datos]. UCI Machine Learning Repository. Recuperado el 6 de octubre de 2026, de https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3.ª ed.). Morgan Kaufmann. https://www.sciencedirect.com/book/9780123814791/data-mining-concep
- Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, *374* (2065), 20150202. https://doi.org/10.1098/rsta.2015.0202
- Pearson, K. (1895). Note on regression and inheritance in the case of two parents. *Proceedings of the Royal Society of London*, *58*, 240-242. https://royalsocietypublishing.org/doi/10.1098/rspl.1895.0041
- Cochran, W. G. (1977). *Sampling Techniques* (3.ª ed.). John Wiley & Sons.
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett,

M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, *17*(3), 261-272. https://www.nature.com/articles/s41592-019-0686-2

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.
- scikit-learn developers. (s.f.). *sklearn.preprocessing.MinMaxScaler*. Recuperado el 2 de agosto de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html
- scikit-learn developers. (s.f.). *sklearn.decomposition.PCA*. Recuperado el 2 de agosto de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html
- Streamlit Inc. (s.f.). *Streamlit Documentation*. Recuperado el 6 de octubre de 2026, de https://docs.streamlit.io/
- Polars developers. (s.f.). *Polars User Guide*. Recuperado el 2 de agosto de 2026, de https://docs.pola.rs/
- NumPy developers. (s.f.). *NumPy documentation*. Recuperado el 2 de agosto de 2026, de https://numpy.org/doc/stable/